
# Projet INF-728 MS BGD 2020-2021 – 22 jan 2021

Nicolas Calligaro Frederic Haykal Julien Maksoud Axel Michalewicz Lingli Zhang







 $\hbox{@\,}2020,$  Amazon Web Services, Inc. or its affiliates. All rights reserved.

Chargement dans une base de

# Cassandra VS MongoDB

Caractéristique	Important pour ce projet	Cassandra	MongoDB
Modèle De Donnée	Oui	Colonnes	+ Documents
Langage De Requête	Oui	Léger et simple	+ Mongo Query Langage (Puissant)
Agrégation	Oui	Néant	+ Aggregation Framework (Compass)
Nœud Principal	Non	+ Multiple	Unique ou Sharding
Passage À L'échelle	Non	+ Native	Null ou Sharding
Schéma	Non	Fixe	+ Schéma Modifiable à Chaud
Chargement Des Données	Non	+ Efficace	Relative
Consistance Des Donnée	Oui	+ Meilleur	Relative (Réplicat Absorbe Crazy Monkey)


#### Besoins du projet GDELT


- Pas de flux continu → Passage à l'échelle pas primordial
- Requêtes complexes de documents nécessaires
- Réduire la quantité de données / Minimiser le nombre de tables





## **Architecture MongoDB (cf cours de Geoffrey)**






Load Balancing



# Import des données dans AWS S3

### 1 fichier de chaque toutes les 15 minutes: masterfilelist.txt





Stockage des raw data (S3)

Mise en DB NoSQL (EC2)

**Traitement (EMR)** 

Requêtage (EC2)

Stockage des

#### Stockage des raw data (S3) Traitement (EMR)

Mise en DB NoSQL (EC2)

Requêtage (EC2)

### Traitement des données dans EMR

